

Adult Census Income

- Predviđanje kategorije prihoda na osnovu popisnih podataka –

Predmet: Softverski algoritmi u sistemima automatskog upravljanja

Autor: Anđela Jelić RA 82/2023

Mentor: Emina Demirović

Novi Sad, jul 2026. godine

1. Opis problema

Problem koji se rešava u okviru ovog projekta je binarna klasifikacija godišnjeg prihoda pojedinca na osnovu demografskih, obrazovnih i profesionalnih karakteristika, korišćenjem skupa podataka prikupljenog iz popisa stanovništva SAD-a (Adult Census Income). Cilj je predvideti da li godišnji prihod osobe prelazi 50.000 dolara (klasa >50K) ili ne (klasa ≤50K).

Poseban naglasak je stavljen na identifikaciju atributa koji najviše doprinose formiranju višeg ili nižeg prihoda, kao i na jasnu vizuelizaciju odnosa između odabranih karakteristika i ciljne promenljive.

Skup podataka

Skup podataka je podeljen na trening (adult_train.csv, 32.561 red) i test (adult_test.csv, 16.281 red) deo, sa ukupno 14 ulaznih atributa i jednom ciljnom promenljivom (income). Atributi obuhvataju:

- age — starost osobe u godinama
- workclass — tip zaposlenja (npr. privatni sektor, državna služba, samozaposlen)
- fnlwgt — statistički ponder (koliko osoba u populaciji odgovara zapisu)
- education / education-num — nivo obrazovanja (tekstualno i numerički)
- marital-status — bračni status
- occupation — zanimanje
- relationship — porodična uloga u domaćinstvu
- race, sex — rasa i pol
- capital-gain, capital-loss — kapitalna dobit/gubitak
- hours-per-week — broj radnih sati nedeljno
- native-country — država rođenja
- income — ciljna promenljiva (≤50K / >50K)

Postupak rešavanja

Projekat je realizovan kroz sledeće faze, svaka implementirana kao zasebna Python skripta u src/ folderu:

- eda.py — eksplorativna analiza skupa podataka
- data_preparation.py — preprocesiranje i enkodiranje podataka
- train.py — treniranje modela (Logistic Regression i Random Forest)
- evaluate.py — evaluacija i poređenje modela
- feature_selection.py — odabir najznačajnijih atributa (wrapper metoda RFE)
- predict.py, app.py, streamlit_app.py — deployment modela kroz API i UI
- run_pipeline.py — pokretanje skripti kroz jedan korak (deployment deo posebno pokrećemo)

2. Početno preprocesiranje podataka

Pre analize i treniranja, podaci su prošli kroz nekoliko koraka čišćenja i pripreme, implementiranih u `data_preparation.py`:

Uklanjanje anomalija u sirovom fajlu

Test fajl (`adult_test.csv`) sadrži tekstualni komentar na prvoj liniji ('1x3 Cross validator') koji ne predstavlja validan red podataka. Ovakvi redovi su detektovani konverzijom kolone `age` u numerički tip (`pd.to_numeric` sa `errors='coerce'`) — svi redovi koji ne sadrže validan broj postaju NaN i uklanjaju se (*dropna*). Dodatno, ciljna promenljiva u test skupu ima tačku na kraju vrednosti (>50K. umesto >50K), što je obrađeno pri enkodiranju.

Nedostajuće vrednosti

Nedostajuće vrednosti u originalnom skupu su označene karakterom '?'. Ove vrednosti su prvo zamenjene sa NaN, a zatim popunjene modom (najčešćom vrednošću) kolone. Analizom je utvrđeno da se nedostajuće vrednosti javljaju u tri kolone:

Kolona	Broj nedostajućih	Procenat
workclass	2.799	5,73%
occupation	2.809	5,75%
native-country	857	1,75%

Popunjavanje *modom* je odabrano jer su sve tri kolone kategorijske sa dominantnom vrednošću (npr. 'Private' za `workclass`, 'United-States' za `native-country`), pa zamena *modom* ne narušava značajno raspodelu i izbegava gubitak ~5-6% podataka koji bi nastao brisanjem redova.

Uklanjanje atributa bez prediktivne vrednosti

Atribut `fnlwgt` (final weight) predstavlja statistički ponder korišćen za ekstrapolaciju uzorka na celokupnu populaciju i ne nosi informaciju o samoj osobi — njegov izuzetno širok raspon (12.285 do 1.490.400, EDA analiza) to dodatno potvrđuje. Atribut je uklonjen iz skupa pre treniranja.

Enkodiranje kategorijskih atributa

Svi kategorijski atributi (`workclass`, `education`, `marital-status`, `occupation`, `relationship`, `race`, `sex`, `native-country`) su enkodirani pomoću *LabelEncoder-a* — svaka kategorija je mapirana u celobrojnu vrednost. Ovaj pristup je odabran umesto *one-hot enkodiranja* jer je korišćen *Random Forest*, algoritam zasnovan na stablima odlučivanja koji prirodno rukuje ordinalno enkodiranim kategorijama bez pretpostavke o linearnom odnosu, a izbegava se i eksplozija dimenzionalnosti (`native-country` ima preko 40 jedinstvenih vrednosti). Enkoderi su sačuvani (`models/encoders.pkl`) radi konzistentne transformacije test podataka i budućih novih zapisa. Nepoznate kategorije u test skupu (koje se nisu pojavile u trening skupu) mapiraju se na najčešću poznatu klasu.

Ciljna promenljiva `income` je *binarno enkodirana*: 1 za '>50K' (uključujući '>50K.' iz test skupa), 0 za '≤50K'.

Standardizacija numeričkih atributa


Svi numerički atributi su skalirani pomoću *StandardScaler-a* (srednja vrednost 0, standardna devijacija 1). Iako *Random Forest* ne zahteva skaliranje, ono je primenjeno radi konzistentnosti sa *Logističkom regresijom* (baznim modelom), koja je osetljiva na skalu atributa.

3. Eksplorativna analiza skupa (EDA)

Eksplorativna analiza (*eda.py*) sprovedena je na objedinjenom, blago očišćenom skupu podataka (trening + test, 48.842 reda) kako bi se uočile korelacije, anomalije i odnosi između atributa i ciljne promenljive pre finalnog enkodiranja.

Korelaciona matrica


Analiza korelacije numeričkih atributa pokazuje da nijedan par ulaznih atributa nema jaku međusobnu korelaciju (multikolinearnost), što znači da nije bilo potrebe za uklanjanjem redundantnih atributa. Sa ciljnom promenljivom, najjaču korelaciju pokazuje education-num (0,33), zatim age i hours-per-week (0,23), i capital-gain (0,22).



Slika 1. Korelaciona matrica numeričkih atributa

Detekcija outliera i ekstremnih vrednosti


Boxplot analiza numeričkih atributa otkriva nekoliko očekivanih obrazaca: capital-gain i capital-loss imaju izrazito veliki broj *outliera* jer je reč o retkim finansijskim događajima (91,7% odnosno 95,3% redova ima vrednost 0) — ovo nije greška u podacima, već prirodna karakteristika atributa. fnlwgt ima vrlo širok raspon vrednosti, što dodatno potvrđuje odluku o njegovom uklanjanju. Kod hours-per-week uočeno je 223 zapisa sa manje od 5h nedeljno i 318 zapisa sa preko 80h nedeljno — ekstremne, ali realno moguće vrednosti (npr. honorarni rad ili više poslova), pa nisu tretirane kao greške i nisu uklanjane iz skupa.



Slika 2. Distribucije numeričkih atributa sa označenim outlierima

Raspodela ciljne promenljive


Skup podataka je neizbalansiran — dominira klasa $\leq 50K$. Ovo je bitno za tumačenje metrika (posebno accuracy) u fazi evaluacije, gde je F1-skor korišćen kao pouzdaniji pokazatelj kvaliteta modela.



Slika 3. Raspodela klasa ciljne promenljive income

Odnos atributa i ciljne promenljive

Vizuelna analiza potvrđuje intuitivne obrasce: viši nivo obrazovanja (Bachelors, Masters, Doctorate) je povezan sa znatno većim udelom osoba u kategoriji >50K; muškarci imaju veći udeo visokih prihoda od žena u ovom skupu podataka; osobe sa prihodom >50K u proseku rade više sati nedeljno i pripadaju starijoj (ali ne najstarijoj) starosnoj grupi u odnosu na osobe sa nižim prihodom.



Slika 4. Odnos obrazovanja, pola, radnih sati i starosti sa ciljnom promenljivom

Zaključak EDA faze

Rezultati EDA analize direktno su usmerili odluke u fazi preprocesiranja: potvrđeno je uklanjanje *fnlwgt*, opravdano je popunjavanje nedostajućih vrednosti *modom* (procenat nedostajućih je nizak), i utvrđeno je da ekstremne vrednosti u *capital-gain/loss* i *hours-per-week* ne predstavljaju greške u unosu već realne, iako retke, vrednosti — te nisu naknadno tretirane niti uklanjanje.

4. Odabir i treniranje modela

S obzirom da je problem binarna klasifikacija sa mešavinom kategorijskih i numeričkih atributa, isprobana su dva algoritma različite prirode radi poređenja performansi:

Logistic Regression (bazni model)

Logistička regresija je odabrana kao jednostavan, interpretabilan bazni model (`solver='liblinear'`, `max_iter=10000`). Njena osnovna pretpostavka je linearna razdvojivost klasa u prostoru atributa, što je razlog zašto se očekuje slabija performansa na ovom skupu u odnosu na modele zasnovane na stablima.

Random Forest (glavni model)

Random Forest je odabran kao glavni model jer prirodno hvata nelinearne odnose i interakcije između atributa (npr. kombinovani uticaj obrazovanja i radnih sati na prihod), otporan je na *outliere* uočene u EDA fazi, i ne zahteva pretpostavku o linearnosti. Dodatna prednost je ugrađena procena značajnosti atributa (`feature_importances_`), korisna za interpretaciju rezultata.

5. Podešavanje hiperparametara

Hiperparametri *Random Forest* modela optimizovani su pomoću *GridSearchCV* sa 3-strukom unakrsnom validacijom (`cv=3`), koristeći *F1*-skor kao kriterijum optimizacije (`scoring='f1'`) — odabran zbog neizbalansiranosti klasa uočene u EDA fazi, gde je *accuracy* manje pouzdana metrika.


Hiperparametar	Isprobane vrednosti
<code>max_depth</code>	5, 10, None
<code>min_samples_split</code>	2, 5
<code>n_estimators</code>	50 (fiksno)

Najbolja kombinacija pronađena pretragom: `max_depth=None` (stabla se granaju do potpune čistoće listova), `min_samples_split=5`. Ovaj model je sačuvan kao finalni *Random Forest* model (`models/best_rf_model.pkl`) i korišćen u svim narednim fazama.

6. Analiza rezultata predikcije

Oba modela su evaluirana na istom, do tada nekorišćenom test skupu (*evaluate.py*), koristeći standardne metrike klasifikacije: tačnost (accuracy), preciznost (precision), odziv (recall), *F1*-skor i *ROC-AUC*.

Metrika	Logistic Regression	Random Forest
Accuracy	0,8253	0,8547
Precision	0,7054	0,7253
Recall	0,4470	0,6199
F1-score	0,5472	0,6684
ROC-AUC	0,8516	0,9022



Slika 5. Grafičko poređenje performansi *Logistic Regression* i *Random Forest* modela


Tumačenje rezultata

Random Forest nadmašuje *Logističku regresiju* na svim posmatranim metrikama. Najveća razlika je u odzivu (recall) — 0,62 naspram 0,45 — što znači da *Logistička regresija* propušta znatno veći broj osoba sa stvarnim prihodom >50K (lažno negativni rezultati), verovatno zato što ne može da modeluje nelinearne interakcije između atributa poput obrazovanja, zanimanja i radnih sati. Viši ROC-AUC *Random Forest* modela (0,90 naspram 0,85) potvrđuje bolju sposobnost razdvajanja klasa nezavisno od praga odlučivanja.

S obzirom na neizbalansiranost klasa uočenu u EDA fazi ($\sim 76\% \leq 50K$, $\sim 24\% > 50K$), *F1*-skor je korišćen kao primarni kriterijum za poređenje modela, jer balansira preciznost i odziv i manje je podložan obmanjujuće visokoj accuracy vrednosti koja bi se dobila i trivijalnim predviđanjem većinske klase. Na osnovu *F1*-skora, *Random Forest* (0,668) je izabran kao finalni model za deployment.

Značajnost atributa (Random Forest)

Ugrađena mera značajnosti atributa (feature_importances_) *Random Forest* modela pokazuje koji atributi najviše doprinose odlukama modela:



Slika 6. Značajnost atributa prema Random Forest modelu

7. Odabir najznačajnijih atributa

Za formalni odabir najznačajnijih atributa korišćena je *wrapper metoda* — *Recursive Feature Elimination (RFE)*, implementirana u *feature_selection.py*. Za razliku od filter metoda (koje ocenjuju attribute nezavisno od modela, npr. na osnovu korelacije) ili embedded metoda (gde se značajnost čita direktno iz jednog već istreniranog modela), *RFE* iterativno trenira model, uklanja atribut sa najmanjim doprinosom, pa trenira ponovo — sve dok ne ostane zadati broj atributa. Odabir je time direktno vođen stvarnim uticajem atributa na performanse modela, po ceni većeg broja treniranja (*RFE* je izvršen za 8,9 sekundi sa *RandomForestClassifier* kao osnovnim estimatorom).

Rangiranje atributa

RFE je primenjen sa ciljem izdvajanja 6 od ukupno 13 raspoloživih atributa. Kompletno rangiranje:


Rang	Atribut	Status
1	age	Zadržan (top 6)
1	education-num	Zadržan (top 6)
1	occupation	Zadržan (top 6)
1	relationship	Zadržan (top 6)
1	hours-per-week	Zadržan (top 6)
1	capital-gain	Zadržan (top 6)
2	marital-status	Eliminisan
3	workclass	Eliminisan
4	capital-loss	Eliminisan
5	education	Eliminisan
6	native-country	Eliminisan
7	race	Eliminisan
8	sex	Eliminisan

Zanimljivo je da su *race* i *sex* rangirani kao dva najmanje značajna atributa — ovaj nalaz je koristan i sa aspekta etičnosti modela, jer sugeriše da model svoje odluke prevashodno zasniva na atributima vezanim za obrazovanje, radno iskustvo i porodičnu situaciju, a ne na demografskim karakteristikama poput pola ili rase.

Poređenje performansi: svi atributi vs najznačajniji atributi

Novi *Random Forest* model treniran je isključivo na 6 izdvojenih atributa, koristeći iste hiperparametre kao pun model (radi fer poređenja doprinosa same selekcije atributa).

Metrika	RF – svi atributi (13)	RF – top 6 atributa
Accuracy	0,8547 (13 atr.)	0,8416 (6 atr.)
Precision	0,7253	0,6890
Recall	0,6199	0,6004
F1-score	0,6684	0,6417
ROC-AUC	0,9022	0,8879



Slika 7. Poređenje Random Forest modela sa svim atributima i sa top 6 atributa

Zaključak

Model sa svim atributima ostaje bolji, ali razlika je relativno mala (0,027 *F1-poena*, oko 4% relativnog pada). Preostalih 7 atributa i dalje nose korisnu, iako manju, prediktivnu informaciju, pa njihovo potpuno uklanjanje nije opravdano ako je prioritet maksimalna tačnost. Redukovani model ostaje razumna alternativa u situacijama gde su brzina treniranja/inferencije ili interpretabilnost važniji od poslednjeg procenta performansi — oba modela su sačuvana kao artefakti (*best_rf_model.pkl* i *best_rf_model_top_features.pkl*).

8. Deployment modela

Finalni Random Forest model je eksportovan (models/best_rf_model.pkl, zajedno sa enkoderima i skalerom) i učinjen dostupnim kroz dva sloja: *REST API* i *grafički korisnički interfejs*.

REST API (Flask)

app.py implementira *Flask* aplikaciju sa dva endpoint-a:

- GET / — vraća status servera i primer očekivanog JSON payload-a
- POST /predict — prima sirove (neenkodirane) podatke o jednoj osobi u JSON formatu i vraća predikciju (>50K / ≤50K) i verovatnoću

Preprocesiranje ulaznih podataka (enkodiranje kategorijskih vrednosti, skaliranje, rukovanje nepoznatim kategorijama) implementirano je u zajedničkom modulu *inference_utils.py*, koji koriste i API i UI, čime se izbegava duplikacija logike i garantuje konzistentnost sa transformacijama primenjenim u fazi treniranja.

Korisnički interfejs (Streamlit)

streamlit_app.py pruža jednostavnu web formu u kojoj korisnik unosi demografske i profesionalne podatke (padajuće liste su automatski popunjene validnim kategorijama iz sačuvanih enkodera, čime se sprečava unos nepostojećih vrednosti). Forma šalje podatke ka *Flask API-ju* i prikazuje rezultat predikcije zajedno sa verovatnoćom u vidu progres trake.

Pokretanje

Sistem se pokreće u dva koraka, iz korena projekta:

- python src/app.py — pokreće API na http://localhost:5000
- streamlit run src/streamlit_app.py — pokreće UI na http://localhost:8501

9. Zaključak

Projekat je pokazao da je *Random Forest*, sa optimizovanim hiperparametrima (`max_depth=None`, `min_samples_split=5`), znatno pogodniji za predviđanje kategorije prihoda na ovom skupu podataka od *Logističke regresije*, prevashodno zbog sposobnosti da modeluje nelinearne odnose među atributima. Postignut je *F1-skor* od 0,668 i *ROC-AUC* od 0,902 na nezavisnom test skupu.

Analiza značajnosti atributa (i *embedded* pristupom i *wrapper* metodom *RFE*) konzistentno je pokazala da su *education-num*, *age*, *hours-per-week* i *capital-gain* među najuticajnijim faktorima, dok demografski atributi poput *pola* i *rase* imaju znatno manji, iako ne zanemarljiv, doprinos.

Ograničenja

- Neizbalansiranost klasa (76% / 24%) ograničava odziv modela za manjinsku klasu (>50K), što se odražava kroz relativno visok broj lažno negativnih predikcija.
- *LabelEncoder* uvodi implicitni ordinalni redosled kategorija (npr. za *native-country*) koji ne postoji u stvarnosti — *one-hot* enkodiranje bi ovo izbeglo, po ceni veće dimenzionalnosti.

Projekat demonstrira kompletan tok rešavanja problema klasifikacije, od sirovih, delimično neurednih podataka do modela dostupnog kroz *API* i korisnički interfejs. Sistematsko poređenje algoritama (*linearni* naspram modela zasnovanog na *stablama*) i dve nezavisne metode odabira atributa (*embedded* i *wrapper*) pokazuju da odluke donete tokom projekta nisu proizvoljne, već potkrepljene merljivim rezultatima na svakom koraku. Postignute performanse (*F1-skor* 0,668, *ROC-AUC* 0,902) predstavljaju solidnu osnovu za ovaj tip problema, uzimajući u obzir prirodu i ograničenja raspoloživog skupa podataka opisana u prethodnom poglavlju.